



Universidad Nacional Autónoma de México

FACULTAD DE CIENCIAS

ALMACENES Y MINERÍA DE DATOS

## *Tarea 1 - Data Warehouse*

Profesora: Jessica Santizo Galicia

Ayudantes: Diego Antonio Villalba González,

Ares Gael Castro Romero

Integrantes del equipo:

Pinacho Báez Arlet - 320287828

Escobar Gonzalez Isaac Giovanni - 321336400

Garduño Escobar Kevin Jonathan - 321070629

Sautto Ramirez Seldon - 321084163

Fecha de entrega:  
25 de febrero de 2026

# Índice

|                                   |          |
|-----------------------------------|----------|
| <b>Conceptos</b>                  | <b>3</b> |
| Ejemplo de Almacén de Datos .     | 3        |
| Diferencias de Almacén de Datos   | 4        |
| <b>Caso de uso</b>                | <b>5</b> |
| Beneficios . . . . .              | 5        |
| Usuarios . . . . .                | 5        |
| Preguntas de interés . . . . .    | 5        |
| Datos y decisiones . . . . .      | 5        |
| Hecho principal . . . . .         | 6        |
| ¿Qué representa una fila? . . . . | 6        |
| Elección de la granularidad . . . | 6        |
| Tipos de granularidad . . . . .   | 7        |
| Esquema estrella . . . . .        | 8        |
| Arquitectura . . . . .            | 8        |
| Rol de cada capa . . . . .        | 8        |
| Capa asociada al modelo estrella  | 9        |
| <b>Detección de errores</b>       | <b>9</b> |
| ETL . . . . .                     | 9        |
| Granularidad . . . . .            | 10       |

## Conceptos

1. Da un ejemplo de Almacén de Datos (de acuerdo con tus intereses, no repetir lo visto en clase) y explica cómo se cumple la definición en tu ejemplo. Incluye:
  - Orientación a temas
  - Integración de datos
  - Variabilidad en el tiempo
  - No volatilidad

### Ejemplo de Almacén de Datos


**Título del DW:** Diseño de un Almacén de Datos para el análisis de sesiones de juego en GTA V Online.

**Descripción del problema:** Rockstar Games desea analizar el comportamiento histórico de los jugadores de GTA V Online con el objetivo de apoyar decisiones estratégicas para el desarrollo de GTA VI. La empresa busca responder preguntas como: cuánto tiempo juegan los usuarios por sesión, cómo evolucionan en nivel, cómo cambian sus ingresos dentro del juego y qué vehículos adquieren. Para ello, se propone diseñar un Data Warehouse centralizado cuyo hecho principal sea la *sesión jugada*.

**Preguntas de análisis:**

- ¿Cuánto tiempo juegan los usuarios por sesión según su edad?
- ¿Qué tipo de jugadores generan mayores ingresos dentro del juego?
- ¿Qué vehículos compran más los jugadores según su nivel?

**Esquema estrella propuesto:**



Según la definición clásica de Inmon (1996), un almacén de datos es una colección de datos orientada a temas, integrada, variante en el tiempo y no volátil, diseñada para apoyar el proceso de toma de decisiones de la administración.

En el ejemplo propuesto para GTA V Online, el Data Warehouse cumple esta definición de la siguiente manera:

- **Orientación a temas:** El almacén está centrado específicamente en el análisis del comportamiento del jugador, particularmente en las sesiones jugadas, la evolución de nivel, los ingresos generados y la adquisición

de vehículos. No se enfoca en transacciones operativas aisladas, sino en un tema analítico claro: el desempeño y comportamiento histórico del jugador.

- **Integración de datos:** El Data Warehouse consolida información proveniente de distintos sistemas del juego, como el perfil del usuario, el sistema económico interno, el sistema de progresión de nivel y el inventario de vehículos. Estos datos se integran bajo estructuras y claves estandarizadas.
- **Variabilidad en el tiempo:** Cada sesión jugada se almacena con su correspondiente referencia temporal, lo que permite analizar la evolución histórica de los jugadores a lo largo del tiempo. Esto posibilita estudios comparativos entre periodos, análisis de tendencias y evaluación del comportamiento.
- **No volatilidad:** Una vez que los registros de sesiones se cargan en el almacén, no se modifican ni eliminan. El sistema únicamente agrega nuevos registros históricos, garantizando estabilidad en los datos y consistencia en los análisis.

De esta manera, el diseño propuesto cumple con los principios fundamentales de un Almacén de Datos y permite transformar datos operativos del videojuego en información estratégica útil para la toma de decisiones empresariales.

## 2. Explica con tus propias palabras la diferencia entre un Almacén de Datos y:

- Una base de datos transaccional: Algunas diferencias pueden ser:
  - Una **base de datos transaccional** es un sistema que nos permite leer, escribir, actualizar, borrar información de manera rápida, constante y en tiempo real.
  - Un almacén de datos está diseñado para analizar la información de manera histórica por ende los datos no se sobre-escriben ni se eliminan, solo se agregan nuevos datos.
  - Además un Almacén de datos puede contener la información de diversas bases de datos transaccionales y puede ejecutar consultas complejas y más rápido que en las bases de datos transaccionales.
- Un esquema estrella: La diferencia sería:
  - El **esquema estrella** es una técnica de diseño que se utiliza dentro de un Almacén de datos.
  - El esquema estrella es la forma en que se organizan las tablas dentro del Almacén de datos.
  - El esquema es el complemento del Almacén.
  - El Almacén es el sistema completo y puede contener varios esquemas estrella.
  - El esquema estrella es lo que usas para construir el Almacén y te indica que estructura va a tener o como se va a construir el Almacén.
- Un cubo OLAP: Se diferencia en que:
  - Un **cubo OLAP** consiste en una estructura de múltiples dimensiones la cual nos permite realizar análisis de datos de manera muy rápida y eficiente gracias a la organización en la que se encuentran los datos.
  - Esta estructura se construye a partir de un almacén de datos, visualmente puede representarse con forma de un cubo pero no necesariamente debe tener esta forma, depende de las dimensiones.
  - Un **almacén de datos** es un repositorio central en donde grandes cantidades de datos de alguna empresa u organización se guardan, con el fin de tener acceso a ellos ya sea para análisis, reportes, toma de decisiones, entre otros.
- Un Data Lake: La diferencia es:
  - Un **Data Lake** es, al igual que el almacén de datos, un repositorio central con la diferencia de que la gran cantidad de datos que se almacenan en este sistema, mantienen su formato original.
  - En el Data Lake los datos no son procesados ni organizados, por lo que puede haber datos estructurados, semiestructurados o no estructurados.
  - El Data Lake contiene los datos crudos.

- Un **almacén de datos** es necesario realizar un proceso de limpieza, estandarización y organización de los datos antes de almacenarlos (proceso de ETL).

## Caso de uso

El Instituto de Matemáticas de la Universidad Nacional Autónoma de México **desarrolla y analiza modelos matemáticos** mediante simulaciones numéricas, orientadas al estudio de ecuaciones diferenciales, sistemas dinámicos, procesos estocásticos y métodos numéricos.

Cada ejecución de simulación genera **información distribuida** que se encuentra **en registros del clúster, bitácoras de ejecución, archivos de resultados y reportes de uso de recursos** computacionales. Actualmente, esta información no va integrada, lo que dificulta el análisis histórico y la toma de decisiones estratégicas.

Por lo anterior, el Instituto te contrata para diseñar un Almacén de Datos que permita **analizar el uso de recursos, el comportamiento de las simulaciones y su evolución** a lo largo del tiempo.

Resuelve los siguientes ejercicios:

1. Menciona qué beneficios tendrá utilizar un Almacén de Datos en un entorno de cómputo científico. Justifica.

Primero nos ayudara integrando todas las fuentes en donde están los datos dentro de un Almacén utilizando un proceso ETL lo que eliminaría inconsistencias en los datos, le daría un único formato y nos daría una única versión de la verdad (En el caso de usar un Data Warehouse Centralizado), además al hacer las consultas ya podríamos hacer comparaciones históricas confiables gracias al almacén e incluso nos permite hacer el análisis histórico en un servidor separado y optimizado a los servidores del clúster lo que nos podría alentar las posibles simulaciones que se estén haciendo lo que nos lleva a que gracias a usar un Almacén de datos el Instituto podría evitar el desperdicio de capacidad de cómputo detectando simulaciones ineficientes o problemas recurrentes también reduciendo costos energéticos y el almacén podría ayudar a la toma de decisiones estratégicas.

2. Indica qué usuarios utilizarían este Almacén de Datos y con qué propósito. Justifica.

- Los Investigadores para analizar desempeño de sus modelos, darse cuenta si los cambios en sus códigos reducen o aumentan el consumo de recursos con respecto a antes.
- Directivos del Instituto para tomar decisiones estratégicas en diferentes ámbitos como el financiero o ver que departamentos les consumen más recursos o en cual hay más productividad.
- Administradores del Clúster para poder monitoriar de mejor manera la saturación que pueda estar teniendo el software o detectar fallos recurrentes, nodos defectuosos o planificar cuando dar mantenimiento a los equipos.

3. Escribe al menos cinco preguntas que el Instituto desearía responder en términos de análisis.

- ¿Qué tipo de modelo matemático consume más recursos computacionales?
- ¿Qué porcentaje de simulaciones fallaron debido a fallas del sistema en el último trimestre, agrupadas por investigador?
- ¿Cómo ha evolucionado el tiempo promedio de ejecución en los últimos 5 años?
- ¿Cuál es el tiempo promedio de ejecución de las simulaciones por cada departamento durante el último año?
- ¿Qué nodos del clúster presentan mayor tasa de fallos?
- ¿En qué periodos del año hay mayor demanda computacional y en cual hay más fallos?
- ¿Qué departamento tuvo más consumo total de recursos computacionales durante el tercer trimestre del año pasado en comparación con el primer trimestre del año actual?

4. Describe qué datos históricos almacenaría el Data Warehouse del Instituto de Matemáticas y qué decisiones estratégicas apoyaría.

Guardaría el historial de cada trabajo computacional con su fecha y hora de inicio y final, el proyecto, la línea de investigación, cantidad de nodos utilizados, memoria RAM utilizada, investigador responsable, departamento de investigación, tipo de procesador utilizado, método numérico usado, estado de finalización. Apoyaría las decisiones estratégicas como por ejemplo de ampliar el clúster o comprar tarjetas RAM o GPUs por fallas del hardware si los datos lo muestran así, o redistribuir cargas de trabajo, poner límites o prioridades para el uso de las distintas herramientas y recursos como priorizar ciertas líneas de investigación o proyectos.

5. Define el hecho principal del modelo multidimensional.

El hecho principal es la ejecución de una simulación, con algunos atributos medibles como:

- Tiempo total de ejecución.
- Memoria RAM máxima utilizada.
- Cantidad de núcleos usados.
- Energía consumida.

6. Explica qué representa una fila en la tabla de hechos y da cinco ejemplos.

Una fila en la tabla de hechos representa un evento medible que ocurre en el negocio, en un nivel específico de detalle (granularidad). En este escenario, el evento central es la Ejecución de una Simulación Numérica, y cada fila almacenará las métricas cuantificables (tiempo de ejecución, memoria usada, CPU consumida, etc.) y llaves foráneas hacia las dimensiones (Tiempo, Simulación, Investigador, Clúster, Proyecto, etc.)

Ejemplos concretos de filas suponiendo que elegimos una fila por ejecución completa de simulación:

- Ejecución del modelo de ecuaciones diferenciales realizada el 10/02/2026 por el Investigador A en el Clúster 1, con duración de 10 800 segundos, 64 GB de memoria utilizada, 85 % de CPU promedio, 8 nodos y 500 MB de resultados generados.
- Ejecución del modelo de sistema dinámico realizada el 12/02/2026 por el Investigador B en el Clúster 2, con duración de 7 200 segundos, 32 GB de memoria utilizada, 78 % de CPU promedio, 4 nodos y 300 MB de resultados generados.
- Ejecución del proceso estocástico realizada el 15/02/2026 por el Investigador A en el Clúster 1, con duración de 14 400 segundos, 96 GB de memoria utilizada, 92 % de CPU promedio, 12 nodos y 850 MB de resultados generados.
- Ejecución del modelo numérico iterativo realizada el 18/02/2026 por el Investigador C en el Clúster 3, con duración de 5 400 segundos, 24 GB de memoria utilizada, 70 % de CPU promedio, 3 nodos y 210 MB de resultados generados.
- Ejecución del modelo de ecuaciones diferenciales realizada el 20/02/2026 por el Investigador B en el Clúster 2, con duración de 12 600 segundos, 80 GB de memoria utilizada, 88 % de CPU promedio, 10 nodos y 600 MB de resultados generados.

7. Se consideran los siguientes niveles de granularidad para el hecho Ejecución de Simulación:

- Una fila por simulación científica
- Una fila por ejecución completa de simulación
- Una fila por paso iterativo interno

Selecciona la granularidad adecuada y justifica por qué es preferible a las demás.

La granularidad más adecuada es “una fila por ejecución completa de simulación”, ya que permite analizar el uso de recursos computacionales, comparar el desempeño entre ejecuciones y evaluar su evolución histórica, que son precisamente las preguntas de interés del Instituto (tiempo de ejecución, consumo de CPU, memoria y nodos utilizados).

Este nivel de detalle es preferible al de “una fila por simulación científica”, porque este último agregaría todas las ejecuciones de un mismo modelo en un solo registro, impidiendo comparar ejecuciones individuales realizadas en

distintos momentos o con distintos parámetros, lo cual es fundamental para evaluar eficiencia y comportamiento a lo largo del tiempo.

Por otro lado, aunque “una fila por paso iterativo interno” ofrecería un nivel de detalle más fino, generaría un volumen masivo de datos que no aporta valor adicional para las métricas estratégicas definidas por el Instituto. Dado que las preguntas planteadas se enfocan en el desempeño global de cada ejecución y no en el análisis matemático interno de cada iteración, ese nivel de granularidad resultaría innecesario y costoso en términos de almacenamiento y procesamiento.

Por ello, una fila por ejecución completa de simulación ofrece el equilibrio adecuado entre detalle analítico y eficiencia del sistema.

8. Explica cuándo sería adecuada una granularidad alta y cuándo una baja, incluyendo sus ventajas y desventajas.


Una granularidad alta (es decir, un nivel de detalle muy fino, como una fila por paso iterativo interno de una simulación) es adecuada cuando se requiere un análisis técnico profundo, por ejemplo, para estudiar el comportamiento interno de un algoritmo, detectar ineficiencias específicas en ciertos pasos del método numérico o analizar fallos muy puntuales en el proceso computacional. Su principal ventaja es que permite un análisis muy detallado y flexible, ya que no se pierde información; sin embargo, sus desventajas son el enorme volumen de datos generado, mayores costos de almacenamiento y procesamiento, y una mayor complejidad en las consultas. En cambio, una granularidad baja (más agregada, como una fila por simulación científica) es adecuada cuando el interés es estratégico y global, por ejemplo, para evaluar el desempeño general de modelos o proyectos sin necesidad de analizar ejecuciones individuales. Su ventaja es que simplifica el modelo, reduce el volumen de datos y facilita consultas rápidas, pero su desventaja es la pérdida de detalle, lo que puede ocultar variaciones importantes entre ejecuciones. Por ello, la elección de la granularidad debe equilibrar el nivel de análisis requerido con la eficiencia del sistema.

9. Dibuja el esquema estrella correspondiente al escenario. Considera que:

- Debe haber al menos cuatro medidas numéricas.
- Deben definirse al menos cinco dimensiones, incluidas Tiempo y Simulación.
- Deben indicarse los atributos relevantes de cada dimensión.

A continuación se muestra el esquema estrella que se diseñó para el escenario del Instituto de Matemáticas con las consideraciones requeridas:

Caso de Uso: Instituto de Matematicas



# 10. Describe las capas de la arquitectura de un Almacén de Datos.

La arquitectura de un Almacén de Datos se compone de varias capas que permiten transformar datos operativos en información útil para la toma de decisiones. La primera capa es **Data Source**, donde se encuentran los sistemas origen, como bases de datos transaccionales, archivos, bitácoras o sistemas externos; en el escenario del Instituto, serían los registros del clúster, archivos de resultados y reportes de uso de recursos. La segunda capa es **Data Staging (ETL)**, donde se realiza la extracción, transformación y carga de los datos: aquí se limpian, integran, estandarizan y preparan antes de almacenarlos definitivamente. La tercera capa es **Data Storage**, que corresponde al Data Warehouse central y, en su caso, a los Data Marts; en esta capa se implementa el modelo multidimensional (como el esquema estrella) y se almacenan los datos históricos ya integrados y listos para análisis. Finalmente, la capa de **Data Presentation** incluye herramientas de análisis, reportes, dashboards, OLAP y minería de datos, que permiten a los usuarios explorar la información, generar indicadores y apoyar la toma de decisiones estratégicas.

# 11. Explica el rol de cada capa en el contexto del cómputo científico.

En el contexto del cómputo científico del Instituto de Matemáticas, cada capa de la arquitectura del Almacén de Datos cumple un papel específico orientado al análisis del desempeño de las simulaciones. La capa de **Data Source** concentra los datos generados por las simulaciones numéricas, como registros del clúster, bitácoras de



ejecución, archivos de resultados y reportes de consumo de CPU, memoria y nodos; es el punto donde se originan los datos crudos. La capa de **Data Staging (ETL)** tiene el rol de integrar esta información dispersa, limpiarla, estandarizar formatos, unificar identificadores de simulaciones e investigadores y calcular métricas relevantes (por ejemplo, tiempo total de ejecución o uso promedio de recursos), garantizando consistencia antes de su almacenamiento. La capa de **Data Storage** almacena los datos históricos ya transformados en el Data Warehouse, implementando el modelo estrella que permite analizar ejecuciones de simulaciones por tiempo, investigador, proyecto o clúster; aquí se conserva la información de manera estructurada y lista para análisis. Finalmente, la capa de **Data Presentation** permite que investigadores y directivos consulten indicadores, generen reportes y realicen análisis comparativos sobre uso de recursos, eficiencia de simulaciones y evolución en el tiempo, apoyando así la toma de decisiones estratégicas sobre infraestructura y planeación científica.

12. Indica dónde se implementa el modelo estrella.

El modelo estrella se implementa en la capa de Data Storage. Es en esta capa donde se diseñan y almacenan la tabla de hechos y las tablas de dimensiones, organizadas en estructura multidimensional para permitir consultas analíticas eficientes.

## Detección de errores

Plantea y describe dos errores de diseño posibles en un Almacén de Datos para este escenario. Los errores no deben impedir la ejecución de consultas, pero sí producir resultados incorrectos o engañosos.

Para cada error, indica:

- Un ejemplo de consulta donde el problema sea evidente.
- Cómo corregirías el error (ETL o modelo).
- Escribe detalladamente los pasos a seguir, así como tu solución.

El principal objetivo de nuestro almacén es la integración de datos provenientes de múltiples fuentes. En particular para nuestro caso de uso, sabemos que el Instituto de Matemáticas distribuye los datos de las simulaciones que realiza en:

- Registros del clúster
- Bitácoras de ejecución
- Archivos de resultados
- Reportes de uso de recursos computacionales

Para poder analizar dos posibles errores de diseño, vamos a suponer que:

- El clúster registra el **tiempo en segundos que trabajó cada nodo** para cada simulación
- Los reportes de uso de recursos registran el **tiempo en minutos de la simulación**

La diversidad de fuentes que maneja el instituto involucra un proceso de transformación riguroso que permita estandarizar la forma en la que se representan los datos, pues si existe un **error en la transformación** se corre el riesgo de obtener resultados erróneos debido a la presencia de datos inconsistentes en el almacén.

De esta forma, un primer error puede ocurrir si nuestro proceso ETL no se diseña de forma adecuada y la transformación no toma en cuenta la diferencia de unidades de tiempo que manejan ambas fuentes, generando inconsistencias en la duración que se registra de las simulaciones.

Este problema se vuelve evidente al momento de buscar conocer estadísticas como el tiempo de cómputo mensual, ya que la falta de homogeneidad en las unidades de tiempo provocará valores sobrestimados o subestimados al momento de sumar las duraciones.

Al ser un error en la transformación de los datos, debe corregirse en el preprocesamiento ETL y no el diseño del modelo. Los pasos a seguir serían:

1. Analizar los distintos formatos presentes en las fuentes de datos

2. Establecer el formato que se desea mantener en el almacén de datos
3. Definir la transformación que requiere cada uno de los distintos formatos que siguen las fuentes de datos para poder cumplir con el formato elegido
4. Verificar que la implementación de la transformación lleve a los resultados esperados

En nuestro error de ejemplo, estos pasos se verían como sigue:

1. El clúster utiliza segundos y los reportes minutos
2. Se eligen minutos pues se espera que las métricas de interés (tiempo de cómputo por mes) sean valores grandes, de forma que la representación en minutos resulta más legible
3. Es necesario convertir los segundos registrados en el clúster a minutos
4. Verificar que la implementación de la transformación sea correcta

Un segundo error puede ocurrir si no se toma en cuenta el significado de los datos con los que se está trabajando, pues este juega un papel importante en la granularidad que sigue el almacén de datos.

Hasta la solución del primer escenario de error pareciera que ya no tenemos problema al sumar las duraciones de las simulaciones; sin embargo, un punto que no se tomó en cuenta es que el clúster tiene registros que corresponden a cada nodo y a cada simulación, mientras que los reportes son más generales, solo guardan la duración total.

Si al momento de *cargar los datos* del clúster estos se guardan como la duración de una simulación, tendremos un **error de granularidad** pues en realidad se tendrían que sumar los tiempos de trabajo de los nodos correspondientes a la simulación en cuestión para poder obtener el valor total, asegurando consistencia con aquello que se extraiga de los reportes.

Entonces, este error no solo involucra el diseño del modelo pues es necesario contemplar si en realidad el Instituto de Matemáticas no requiere que la granularidad corresponda a cada nodo del clúster, sino además es necesario que el proceso ETL se realice de forma que las transformaciones aplicadas a los datos y su carga al almacén no ignoren o modifiquen su significado.

Así los pasos finales para evitar ambos errores serían:

1. Notar que el clúster utiliza segundos y los reportes minutos.
2. Tomar en cuenta que el clúster guarda el tiempo que utilizó **cada nodo** en cada simulación, pero los reportes guardan la duración **total** de la simulación.
3. Elegir minutos pues se espera que las métricas de interés sean valores grandes, de forma que la representación en minutos resulta más legible. Aunque la elección claramente depende de los requerimientos.
4. Convertir los segundos registrados en el clúster a minutos y sumar los tiempos de cómputo de cada nodo que estén asociados a una misma simulación.
5. Verificar que la implementación de la transformación sea correcta y que la carga de los datos no altere la granularidad.