



Universidad Nacional Autónoma de México

FACULTAD DE CIENCIAS

ALMACENES Y MINERÍA DE DATOS

Tarea 2 - EDA, Personas desaparecidas en México

Profesora: Jessica Santizo Galicia

Ayudantes: Diego Antonio Villalba González,

Ares Gael Castro Romero

Integrantes del equipo:

Pinacho Báez Arlet - 320287828

Escobar Gonzalez Isaac Giovani - 321336400

Garduño Escobar Kevin Jonathan - 321070629

Sautto Ramirez Seldon - 321084163

Fecha de entrega:
26 de marzo de 2026

Índice

Objetivos y preguntas de Análisis	3
1. Objetivo	3
2. Preguntas de análisis	3
Descripción del dataset	3
Hallazgos Principales	5
Limitaciones	9
Conclusiones	9

Objetivos y preguntas de Análisis

Dado el dataset asignado al equipo sobre personas desaparecidas en México, se establecieron una serie de objetivos que sirvieron como guía para el desarrollo del análisis exploratorio de datos. Asimismo, a partir de estos objetivos, se formularon preguntas de análisis orientadas a identificar patrones relevantes y comprender mejor el fenómeno estudiado.

1. Objetivo

El objetivo principal de este análisis es estudiar el fenómeno de las personas desaparecidas en México a partir de la información disponible en el dataset, con el fin de identificar patrones geográficos, temporales y operativos relacionados con los procesos de registro y búsqueda.

A través del uso de técnicas de estadística descriptiva y visualización de datos, se busca analizar la distribución de los casos, así como la relación entre las distintas fuentes de información (RNPEDNO y RNPED) y los mecanismos institucionales de búsqueda implementados.

Dichos resultados que obtuvimos no serán usados para un modelo predictivo, más bien tienen como finalidad aportar información relevante y útil para la toma de decisiones por parte de las autoridades competentes, así como para sensibilizar a la sociedad sobre la magnitud y características del fenómeno de las desapariciones en México.

2. Preguntas de análisis

De acuerdo al dataset y las variables que se tienen disponibles, se plantearon las siguientes preguntas de análisis para tener un enfoque claro durante el proceso de exploración de los datos por nuestro equipo:

1. ¿Cuáles son las entidades federativas con mayor número de casos de desaparición?
2. ¿Cómo se distribuyen los casos de desaparición a lo largo del tiempo?
3. ¿Qué estatus de búsqueda es el más frecuente dentro de los registros?
4. ¿Existe una concentración significativa de casos en ciertas entidades del país?
5. ¿Se observa concentración de desapariciones en determinados periodos de tiempo?
6. ¿Qué tan integrados están los registros entre las distintas fuentes de información (RNPEDNO en formatos JSON y CSV, y RNPED)?
7. ¿Qué relación existe entre los procesos de búsqueda (bg_1 y bg_2) y las fuentes de datos disponibles?
8. ¿Existen diferencias entre los registros provenientes del sistema anterior (RNPED) y el sistema actual (RNPEDNO)?

Estas preguntas permiten orientar el análisis hacia la identificación de patrones clave en los datos, asegurando coherencia con las variables disponibles y con los objetivos del estudio.

A partir de estos objetivos y preguntas definidas, se desarrollo el análisis exploratorio de datos en busca de cumplir nuestros criterios de éxito establecidos, y no dejar de lado una parte importante el cual es tener un manejo ético de la información, dado que se trata de un tema sensible que involucra a personas desaparecidas y debe de tratarse con la debida responsabilidad y respeto.

Descripción del dataset

El dataset que se nos fue asignado corresponde al registro de personas desaparecidas en México, en el cual se trabajo y realizo los respectivos procesos de limpieza y transformación de datos para poder realizar un análisis exploratorio adecuado, ya que el dataset original presentaba una serie de inconsistencias, datos faltantes, entre otros problemas.

A partir de un diagnostico inicial para entender mejor el dataset, se identificaron las siguientes características principales del mismo:

El dataset contiene un total de 89,720 registros (filas) y cuenta con 13 variables (columnas), a continuación se describen las variables más relevantes:

1. **Unnamed: 0**: índice del registro.
2. **nombrecompleto**: nombre de la persona.
3. **rnpdno_json**: indicador binario de presencia en extracción JSON.
4. **entidad_desap**: entidad federativa asociada al caso.
5. **pre_rnped**: indicador binario (versiones previas de RNPED).
6. **rnped**: indicador binario (RNPED).
7. **rnpdno_csv**: indicador binario de presencia en extracción CSV.
8. **bg_1**: indicador binario (primera publicación de búsqueda generalizada).
9. **estatus_busqueda**: categoría administrativa de estatus de búsqueda.
10. **bg_2**: indicador binario (segunda publicación de búsqueda generalizada).
11. **fub**: folio único de búsqueda.
12. **DC_id**: identificador de registro por fuente/formato.
13. **fecha_desap**: fecha de desaparición (formato texto en origen).

Cada fila representa a una persona que ha sido reportada como desaparecida, o bien, como persona no localizada, las variables describen características demográficas, geográficas y administrativas relacionadas con cada caso.

Además, tenemos que el dataset contiene información que proviene de distintas fuentes oficiales (RNPEDNO, RNPED, entre otras) y que se encuentra en distintos formatos (JSON, CSV), dándonos un panorama amplio al momento de analizar la información, pero también presentando el reto de integrar y limpiar los datos para obtener un análisis coherente y significativo.

Como se mencionó anteriormente, el dataset original presentaba algunos puntos críticos pues no estaba limpio, algunos de los problemas que se identificaron fueron los siguientes:

- Alta presencia de valores faltantes (NA) en variables clave:
 - **estatus_busqueda**: 27,364 faltantes.
 - **fub**: 26,050 faltantes.
 - **DC_id**: 9,651 faltantes.
 - **fecha_desap**: 6,925 faltantes.
- Inconsistencias en **fecha_desap**: coexistencia de registros con una sola fecha y registros con múltiples fechas concatenadas en una sola celda.
- Posibles duplicidades semánticas (personas con mismo nombre) que requieren criterio de deduplicación más allá de coincidencia exacta.
- Heterogeneidad en variables categóricas (formato, acentos, espacios y combinaciones de categorías en **estatus_busqueda**).

Aun con estas inconsistencias, el dataset fue capaz de ofrecernos datos suficientes para permitirnos realizar análisis de distribución por entidad, estudiar comportamientos temporales, describir la concentración de casos por estatus de búsqueda, entre otros aspectos relevantes para entender dicha problemática social.

Todo lo mencionado corresponde a la descripción del dataset en su estado original, posteriormente se realizaron los procesos de limpieza y transformación de datos para poder obtener un dataset limpio.

Hallazgos Principales

A partir del análisis exploratorio del dataset de desapariciones en México, se identificaron los siguientes hallazgos principales sustentados en medidas estadísticas y visualizaciones:

1. **El estado con mayor número de desapariciones es Tamaulipas.** Esto se determina a partir de la moda de la variable *entidad_desap*. Es decir, el valor más frecuente dentro del conjunto de datos.




Figura 1: Estados con más desapariciones.

2. **Existe una alta concentración de casos en ciertos estados.** El índice de concentración para entidad (0.5098) indica que una proporción importante de los casos se acumula en pocas entidades. Esto implica que el fenómeno de desapariciones no afecta de manera homogénea al país, sino que existen focos geográficos donde el problema es significativamente mayor.




Figura 2: Curva de Lorenz - Entidad desaparición.

3. **La distribución de desapariciones por estado presenta alta dispersión.** El rango de 11,831 casos muestra una diferencia significativa entre el estado con más y menos registros. Esto, junto con la desviación estándar, evidencia una variabilidad elevada entre estados, lo que sugiere que el fenómeno presenta comportamientos muy distintos dependiendo de la región.




Figura 3: Dispersión de proporciones por entidad.

4. **El estatus más frecuente es “Se busca reportante”.** Esto indica que una gran proporción de los casos se encuentra en esta categoría. Esto sugiere que una proporción importante de los casos se encuentra en una etapa inicial o con información incompleta dentro del proceso de búsqueda.




Figura 4: Distribución del estatus de búsqueda

5. **Los casos se concentran fuertemente en ciertos estatus.** El rango de 22,861 y una desviación estándar elevada reflejan una distribución desigual entre categorías. Algunas categorías concentran una gran cantidad de casos, mientras que otras tienen una participación mucho menor.




Figura 5: Dispersión del estatus de búsqueda

6. **El año con mayor frecuencia de desapariciones es 2019.** Esto se obtiene a partir de la moda de la variable *anio_desap*. Este resultado indica que en dicho año se registró el mayor número de desapariciones dentro del periodo analizado.




Figura 6: Desapariciones por año

7. **Existe una alta concentración temporal de los casos.** El índice de concentración por año (0.7440) indica que ciertos periodos concentran gran parte de las desapariciones.




Figura 7: Curva de Lorenz - Año de desaparición

8. **Las desapariciones presentan una variabilidad importante a lo largo del tiempo.** El rango de 6,740 casos entre años refleja diferencias significativas entre periodos.




Figura 8: Desapariciones por año

Limitaciones

- Una de las principales limitaciones para analizar el conjunto de datos, sin duda fue la existencia de múltiples fechas para un mismo registro pues no nos permitió poder identificar la fecha correcta de la desaparición.
- Otra limitación importante fue el duplicado en 9,651 registros de una cadena de múltiples fechas (aproximadamente 2,772) en el campo de fecha de desaparición pues esto no solo imposibilita el conocimiento de la fecha correcta, sino que además deja en duda la confiabilidad de los registros.
- Además, complementando el punto anterior en el dataset existen registros que tienen la misma cadena de fechas pero así como esa hay otra cadena de fechas diferente que se repite en muchos otros registros, también celdas con pocas pero más de una fecha lo que nos obligo a transformar estos registros a valores nulos de tiempo para asumir información que puede ser errónea, que como consecuencia nos deja sin la posibilidad de ubicar cronológicamente a estas víctimas en el análisis por fechas.
- Uno de los sesgos más grande es que estos datos reflejan solamente las desapariciones que han sido reportadas, cargadas al sistema y permanecido en el, esto nos lleva a que podamos creer que los estados que aparecen con mayor concentración de casos podrían ser aquellos en los cuales se denuncian y se registran las desapariciones de manera más eficiente, mientras que la situación real podría estar sesgada porque en algunas entidades hay un peor servicio de las instituciones o mayor temor a denunciar.
- El dataset presentó una cantidad grande de valores faltantes en donde solo había un texto **NA**. Además el dataset carece de información que podría ser útil como edad o contexto de la desaparición.
- Al tratar con un tema tan delicado como lo es la desaparición de personas en nuestro país, las decisiones que tomamos acerca de la limpieza priorizaron el no borrar registros, si bien si se borraron algunos registros fue bajo un criterio que establecimos exigiendo que coincidieran exactamente cuatro columnas (**nombrecompleto**, **entidad_desap**, **fub** y **fecha_desap**) para eliminar los duplicados ya que podemos inferir que se trata del mismo caso de desaparición, mientras que para el caso de los nulos simplemente los rellenamos con el texto "Desconocido" para no descartar todo ese registro.
- A pesar de que el análisis pueda correr el riesgo de tener redundancia o ruido por casos duplicados que no cumplieron con nuestro criterio para eliminación, preferimos esto a poder caer en el error ético de borrar a una víctima real del dataset.

Conclusiones

A lo largo del Análisis Exploratorio del conjunto de datos asignado, *tot_reg_desap.csv* se aplicaron distintas medidas estadísticas para conocer como se distribuyen los datos. Dicha aplicación permitió entender el tipo de valores contenidos en cada una de las columnas del conjunto de datos, entender la manera en la que aparecen e identificar posibles relaciones entre variables.

Si bien fue posible llegar a conclusiones como que el estado con mayor aparición en los registros es Tamaulipas, no debemos olvidar que esto no implica que sea en realidad el estado en el que más desaparecen personas, pues uno de los principales desafíos en este caso de estudio es precisamente la dificultad de registrar a la totalidad de las personas desaparecidas o no localizadas.

Sin duda, el trabajar con datos relacionados a registros de la vida real representó un reto pues la calidad de los datos no está tan cuidada como en los conjuntos de datos con fines educativos que hemos estado revisando en clase. No obstante, al ser una problemática de suma importancia en el país, desde la etapa de entendimiento del problema hasta la limpieza de los datos contribuyeron al desarrollo de una visión más crítica entorno a la forma en la que se manejan los datos a nivel nacional.